

Sous le capot des stéréotypes : étude des rôles genrés dans la publicité automobile

Lucile Lapray et Clotilde Carrotte

Note de recherche pour un projet final du cours “Cas d’application en sciences des données” dispensé par Christophe Benavent dans le cadre du CPES 3 DAC.

1. Introduction

Pour promouvoir des biens, la publicité met en scène des éléments qui façonnent l’imaginaire collectif facilement reconnaissables pour les spectateurs, tels que des mythes ou des archétypes, dans le but de faciliter leur engagement avec le produit mis en avant. Elle s’appuie en effet sur des récits culturels préexistants pour rendre un objet désirable (E. Opran, 2025). La publicité est donc le reflet des normes sociales dominantes, notamment autour de la construction du genre, et participe à la circulation de récits symboliques sur ce que signifie être un homme ou une femme. Nous nous intéressons spécifiquement aux publicités automobiles télévisées, historiquement sujettes aux représentations stéréotypées des genres.

Ce projet propose d’étudier, par une approche quantitative, la répartition des rôles, la quantité et la nature des discours attribués aux hommes et aux femmes dans les publicités télévisées pour voitures. Nous faisons l’hypothèse que les femmes y occupent encore des positions secondaires, tant en volume de parole qu’en complexité de discours, malgré l’évolution des attentes sociétales qui tendent vers davantage d’égalité.

2. Cadre théorique

Les représentations de genre dans la publicité s’inscrivent dans un cadre plus large de rôles sociaux et de hiérarchies de genre. Historiquement, l’automobile a été construite comme un territoire masculin. Cette association d’une construction culturelle alignée sur ce que R.W. Connell nomme la « masculinité hégémonique », qui valorise la prise de risque, la compétence technique et la domination sur l’environnement. A l’inverse, les femmes sont souvent associées à des rôles domestiques et de soin, car majoritairement mises en scène conduisant des véhicules de petit format pour des trajets quotidiens. Dans cette perspective, la publicité associe implicitement certains types de véhicules à des identités de genre spécifiques, en construisant des récits où la performance, l’aventure et la maîtrise technique sont des attributs masculins, tandis que la sécurité, la praticité et la gestion domestique sont assignées aux femmes (Y. Demoli, P. Lannoy, 2019). Cette idée semble corroborée par une analyse de contenu menée sur des publicités automobiles en Inde, qui montre par exemple que ces publicités privilégient significativement des personnages masculins en position dominante, avec des voix off masculines ou des présentations de produits centrées sur des usages masculins (N. Sandhu, 2019).

Nous avons ainsi établi plusieurs prédictions à partir de nos lectures, afin de créer des visualisations et de les tester statistiquement.

Prédiction n°1 : Les femmes parlent moins souvent que les hommes.

Prédiction n°2 : Les femmes et les hommes ne parlent pas des mêmes sujets.

Prédiction n°3 : La complexité grammaticale des femmes est moins grande que celle des hommes

Prédiction n°4 : Les femmes sont plus souvent entendues en voix off qu'en tant qu'actrices des publicités. On suppose que les femmes sont plus susceptibles d'être utilisées pour présenter les produits que pour permettre à de potentiels acheteurs de s'identifier en jouant un rôle concret dans les publicités.

Prédiction n°5 : Les femmes apparaissent principalement dans les publicités mettant en avant des voitures de petit format.

3. Méthode

Nous utilisons un jeu de données de publicités automobiles télévisées, comprenant des informations variées, notamment sur les modèles des voitures, les marques, les chaînes de diffusion et les scripts ($n = 8938$).

a) Traitement des données textuelles

Nous avons réalisé un important prétraitement des données pour extraire le genre et le mode d'énonciation du locuteur prononçant chaque phrase dans les scripts, à partir du formatage du texte. Nous avons ainsi constitué une base de 5704 phrases annotées. Chacune de ces phrases est également associée à une liste de tokens, complétée par un compte du nombre de tokens dans la phrase.

Ce traitement du texte a été effectué en utilisant notamment des regex et la tokenisation par le module Spacy à partir de la pipeline "fr_core_news_md".

On peut ainsi avoir, par exemple, une phrase énoncée dans le script à l'index 3, par une femme, en voix-off, contenant 4 tokens : ["découvrir", "la", "nouveau", "voiture"]. Lorsque le genre n'est pas clairement identifié dans le script, on note que le genre est indéterminé.

b) Ajout de variables

En aplatissant ce jeu de données de phrases issus des scripts du jeu de données initial, nous obtenons des variables telles que le nombre de tokens prononcés par un homme acteur, un homme en voix-off, une femme actrice, une femme en voix-off, etc. A partir de ces comptes, nous avons pu établir une évaluation de la disparité du temps de parole, en fonction du genre. La variable de Différence de Tokens par Genre est donc simplement une soustraction du nombre total de tokens prononcés par une femme au nombre total de tokens prononcés par un homme. Cette variable a été normalisée pour prendre en compte le nombre total de tokens prononcés dans le script.

Nous n'avions pas à disposition les données nécessaires pour tester l'hypothèse n°5. Nous avons donc réalisé une annotation de la taille des voitures par un LLM (*DeepSeek*) à partir des données de modèles de marques. Dans une discussion, nous avons demandé à un LLM de retrouver

les dimensions de quarante modèles de voiture, en continuant jusqu'à avoir récupéré des données pour tous les modèles du jeu de données.

c) Description du corpus

Les variables que nous avons utilisées dans notre étude sont décrites ci-dessous. En particulier, nous avons représenté la distribution des comptes de phrases et de tokens avec des graphiques en barres, utiles pour mesurer le temps de parole des individus, et la répartition de ces distributions avec les boîtes-à-moustaches en dessous.

En retirant les *stop words* et les nombres, nous obtenons un corpus composé de 1910 mots différents pour un total de 614 hyperonymes. Nous avons également représenté les quinze mots les plus fréquents chez les hommes et les quinze mots les plus fréquents chez les femmes sous forme d'une unique matrice de fréquence :

Token	Femme	Homme
être	531	829
avoir	151	441
nouveau	208	308
tout	85	227
renault	139	141
électrique	139	125
euro	113	144
plus	61	176
aller	87	143
voiture	87	137
hybride	88	126
oui	39	150
là	50	134
partir	74	108
faire	87	93
mois	83	83
pouvoir	35	121
cela	27	125
non	66	72
découvrir	61	63

Tableau 1. Matrice de fréquence des 15 tokens les plus fréquents pour chaque genre le corpus




Figure 1. Description de la distribution des tokens selon le genre du locuteur




Figure 2. Distribution de la différence de tokens selon le genre, par script




Figure 3. Distribution du volume des modèles de voiture

d. Modélisations statistiques

Afin de tester la prédiction n°1, nous avons effectué un t-test pour comparer le nombre moyen de tokens prononcés par les hommes et par les femmes.

La prédiction n°2 est exploratoire.

Afin de tester la prédiction n°3, nous avons effectué un t-test pour comparer la complexité lexicale des répliques prononcées par les hommes avec celles prononcées par les femmes.

Afin de tester la prédiction n°4, nous avons réalisé un test du Chi-2 pour mesurer la différence de répartition du type de voix selon le genre.

Afin de tester la prédiction n°5, nous avons réalisé une régression linéaire pour évaluer la corrélation entre le nombre de tokens prononcés par des femmes et la taille de la voiture.

4. Résultats

a. Les femmes parlent moins que les hommes dans les publicités de voiture.

Sur notre première prédiction de différence de présence orale des femmes par rapport aux hommes, notre hypothèse a rapidement été soutenue par la description des données où l'on voit que le nombre de phrases et de tokens prononcés par des femmes compte pour environ une moitié du nombre de tokens prononcés par des hommes (voir *Figure 1*).

Genre	Moyenne du nombre de phrases prononcées par script	Ecart-type
Homme	0.89	0.77
Femme	0.44	0.59

Résultat du t-test : $t = 26.464$ $p\text{-value} < 0.0001$

Conformément à notre prédiction, l'hypothèse selon laquelle les hommes et les femmes parlent autant est rejetée de manière significative.

b. Les femmes sont pragmatiques ou séductrices, les hommes sont innovants ou libres.

Afin d'explorer notre deuxième hypothèse, sur la différence du contenu des discours masculins et féminins, nous avons réalisé une modélisation de thèmes en utilisant l'allocation de Dirichlet latente (LDA). A partir de ces thèmes, nous avons produit des nuages de mots, en distinguant les phrases prononcées par des hommes de celles prononcées par des femmes.



Figure 4. Topics extraits des paroles des femmes



Figure 5. Topics extraits des paroles des hommes.

Note : les mots de couleur cyan sont des mots majoritairement prononcés par des hommes, les mots bleus sont majoritairement prononcés par des femmes.

Certaines thématiques sont représentées chez les femmes comme les hommes. Sur les dix thématiques pour chaque genre étudié, six sont communes. On retrouve des manifestations similaires pour les thèmes que l'on a nommé : Technologie Hybride (Topic F. 0, Topic H. 1), Transition Électrique (Topic F. 1, Topic H. 9), Offres et Financements (Topic F. 3, Topic H. 6), Évasion (Topic F. 4, Topic H. 2), Mobilité Urbaine (Topic F. 6, Topic H. 8) et enfin Plaisir de Conduire (Topic F. 8, Topic H. 7).

Néanmoins, on peut aussi entrevoir une divergence. Les femmes ont des réflexions pragmatiques (Budget et Accessibilité, Famille et Quotidien), ou bien servent à rendre la marque attractive, plus dans un rôle de vendeuses que de consommatrices (Design et Séduction, Renouveau des Marques). Quant aux hommes, ils mettent en avant les innovations techniques, principalement des plus gros modèles (Gamme SUV & Innovation, Électrification & Modèles) ou vantent des concepts traditionnellement associés à la masculinité et à une consommation automobile personnelle, individuelle, loin du quotidien pragmatique dont parlent les femmes (Aventure & Liberté, Expérience de Voyage).

c. Aucune différence de complexité du discours selon le genre du locuteur.

Nous comptions initialement calculer un indice de lisibilité pour évaluer la complexité lexicale de la parole dans les publicités automobiles. Après quelques recherches, nous avons constaté que des indices semblables à l'indice Flesch n'étaient pas adaptés dans notre cas car conçus pour des textes écrits et non oraux.

Nous avons donc décidé de mesurer la complexité syntaxique, via l'indice de Shannon qui permet d'évaluer la diversité des catégories grammaticales en s'appuyant sur les POS obtenue grâce à un modèle de la bibliothèque spacy, construit comme suit :

$H = -i \sum p_i \log(p_i)$ avec p_i est la proportion des mots appartenant à la catégorie grammaticale i .

Plus un discours mobilise de catégories grammaticales différentes, plus sa structure syntaxique est variée donc plus il est complexe. En effet, un texte simple tend à utiliser beaucoup de noms et quelques verbes, tandis qu'un texte plus compliqué mobilise davantage d'adjectifs, d'adverbes, de conjonctions, etc.

En moyenne les femmes ont une complexité lexicale de 1.180 et les hommes de 1.178, mais cette différence n'est pas significative ($t = -0,145$, $p = 0,884$). La diversité syntaxique très faible pour les deux groupes est cohérente avec notre corpus publicitaire, principalement constitué de slogans et de descriptions brèves.

d. Les voix des femmes s'entendent en off, les hommes sont les acteurs de la publicité.

Nous présentons ici la table de contingence des tokens selon le genre, ainsi que les proportions associées à l'assignation des types de voix. Les résultats montrent que 56,74 % des tokens prononcés par les femmes correspondent à des voix-off, contre 48,73 % chez les hommes.





Figure 6. Table de contingence selon le type de voix, par genre

Un test du Chi-2 a été réalisé afin d'évaluer si la répartition des types de voix diffère significativement selon le genre. Les résultats sont hautement significatifs ($\text{Chi-2} = 210,67$, $p < 10^{-47}$), ce qui indique que les Les femmes parlent proportionnellement plus en tant que voix-off qu'en tant qu'actrices que les hommes. Notre prédiction est vérifiée.

e. La taille de la voiture n'a pas de lien avec la parité de genre dans la publicité qui cherche à la vendre.

Pour explorer notre dernière hypothèse, nous avons réalisé une régression linéaire afin d'évaluer la corrélation entre le nombre de tokens prononcés par les femmes et le volume des voitures présentées.



	Coefficients	Standard error	t	p-value
Intercept	2.7902	1.065	2.621	0.009
Volume	-0.0021	0.089	-0.024	0.981

Tableau 2. Table de régression

Les résultats montrent que le coefficient associé au volume est très proche de zéro ($\beta = -0,0021$, $p = 0,981$). Le R^2 de la régression est quasi nul ($R^2 = 0,000$), indiquant que le modèle n'explique aucune variance du nombre de tokens prononcés par les femmes en fonction de la taille du véhicule.

Ces résultats suggèrent donc que la taille de la voiture n'a pas de lien avec la répartition de la parole selon le genre dans les publicités, contredisant l'idée selon laquelle les femmes seraient systématiquement associées à des véhicules plus petits ou plus pratiques.

5. Conclusion

Les résultats de cette analyse donnent à voir un paysage de la publicité automobile conscient que les femmes sont des consommatrices au même titre que les hommes. Le discours est donc adapté en conséquence. Néanmoins, la parité n'est pas du tout atteinte et la quantité de parole des femmes ne constitue qu'un tiers de la quantité globale.

6. Références bibliographiques

Opran, E. (2025). *The relationship between advertising, archetypal imaginaries and myths*. Social Sciences and Education Research Review, 12, 213–216.

Demoli, Y., & Lannoy, P. (2019). *Sociologie de l'automobile*. Paris, France : La Découverte.

Sandhu, N. (2019). *Fueling gender stereotypes: A content analysis of automobile advertisements*. EconPapers.